

A decisão limitada antes do modelo

Um guia curto para escolher entre código, uma decisão semântica limitada e um modelo generativo - e para manter validação, permissões e execução sob controle da aplicação.

OBJETIVO

Encontre um caso finito que possa ser testado contra o fluxo atual. Não requer acesso ao Jev.

1. Descreva uma decisão real

Preencha antes de escolher qualquer modelo. Se as saídas ou o fallback ainda não estão claros, reduza o escopo primeiro.

Entrada que o sistema recebe:

Saídas permitidas (IDs estáveis):

Ação posterior à decisão:

Quem valida e executa essa ação:

O que ocorre com resposta desconhecida, ambígua ou indisponível:

2. Use a opção mais simples que resolve

TIPO DE DECISÃO	COMECE COM	EXEMPLO
Regra exata sobre dado confiável	Código determinístico	amount > 500 exige revisão
Julgamento semântico com opções finitas	Avalie um decisor limitado	Mensagem vai para uma de quatro filas
Texto ou raciocínio aberto	Modelo generativo	Redigir resposta com contexto
Ação de alto impacto	Política determinística + aprovação	Autorizar pagamento ou exclusão

Uma chamada de decisão não é automaticamente melhor do que uma condição simples. Compare com o caminho atual antes de substituir algo.

3. Esboce o fluxo seguro

Mantenha as regras determinísticas e a autorização final na aplicação. O decisor sugere uma opção; não executa a ação.

01	Entrada	Receba apenas o contexto necessário.
02	Regras exatas e permissões	Aplique negações, limites e verificações em código.
03	Opções limitadas	Envie ao decisor somente as alternativas permitidas.
04	Validar resultado	Confira enum/ID contra uma allowlist local.
05	Fallback	Em timeout, ID inválido ou incerteza, use caminho seguro ou revisão.
06	Autorizar e executar	A aplicação decide se a ação pode ocorrer e a executa.

Exemplo: roteamento de suporte

Um classificador propõe billing, technical, account ou review. A aplicação continua responsável por validar acesso, proteger dados e executar qualquer ação.

- Rejeite qualquer ID fora dessas quatro opções.
- Encaminhe review, erro ou baixa confiança para uma fila controlada por uma pessoa.
- Faça verificações de acesso antes de consultar ou alterar dados da conta.
- Registre categoria, confiança quando disponível, latência e uso de fallback; evite guardar conteúdo privado desnecessário.

REGRA DE BOLSO

Seleção de ferramenta é dado de entrada, não autorização. Permissões, validação e execução continuam no código da aplicação.

4. Compare com o baseline

Rode os mesmos casos no sistema atual e na alternativa. Rotule a resposta esperada antes de examinar os resultados.

```
case_id, expected_route, selected_route, correct, valid_output, latency_ms, fallback, cost_basis
```

Inclua casos representativos. Mantenha separado o conjunto usado para ajustar limiares e reavalie quando dados, prompt, modelo ou SDK mudarem.

5. Decida com evidência

Analise o fluxo ponta a ponta, incluindo retries e fallbacks. Uma demonstração isolada não prova desempenho.

MEDIDA	PERGUNTA
Correção da rota	Escolheu a opção esperada?
Saída válida	Retornou uma opção permitida?
Fallback	Quantos casos voltaram ao caminho antigo ou foram para revisão?
Latência ponta a ponta	Incluiu chamadas adicionais e retries?
Custo total do fluxo	Incluiu fallback, tokens/contexto e infraestrutura pertinente?
Impacto de erro	O que ocorre quando escolhe a opção errada?

Resultado do seu teste

Baseline usado (versão, regra ou modelo):
Tamanho e origem do conjunto de casos:
Principal risco ou surpresa observada:

Critério para seguir ou parar

- ☐ Seguir para teste controlado: opções finitas, validação e fallback implementados, baseline comparável.
- ☐ Manter código: as regras exatas resolvem o caso de modo claro e confiável.
- ☐ Escalar para uma pessoa: erro caro, input ambíguo, serviço indisponível ou confiança não validada.
- ☐ Parar: o resultado não melhora o fluxo completo ou o custo operacional extra não compensa.

Limites

Este worksheet não prova que Jev é mais rápido, barato, preciso ou seguro no seu caso. Jev é uma opção para avaliar decisões semânticas limitadas. Acesso ao Jev e cobrança do fornecedor são separados. Verifique SDKs e termos atuais antes de implementar.

PRÓXIMO PASSO

Escolha uma decisão limitada e preencha as cinco linhas da seção 1. Para mais exemplos TS/Python, 16 receitas, estudos de caso e um harness offline, veja o Jev Operator Kit v0.1 por US\$19.

jevtools.gumroad.com//jev-operator-kit

Disclosure: esta amostra e o kit pago são do mesmo autor. Produto em v0.1; sem resultados de benchmark alegados.